

Discipline scientifiche

Descrizione del dataset

Il dataset è composto dai seguenti elementi principali:

- **Discipline**: un insieme di settori scientifici appartenenti all'ingegneria, matematica, fisica, scienze naturali e scienze sociali. Ogni disciplina è identificata da un nome univoco.
- **Size delle discipline**: a ciascuna disciplina è associato un valore numerico che rappresenta la sua "grandezza" nel dataset. Questo valore non corrisponde necessariamente al numero esatto di articoli, ma è una misura aggregata/normalizzata della produttività scientifica della disciplina.
- **Matrice dei flussi**: una matrice quadrata in cui l'elemento F_{ij} indica il flusso di citazioni **dalla disciplina i verso la disciplina j** . In altre parole, F_{ij} rappresenta quante volte gli articoli prodotti nella disciplina i citano articoli appartenenti alla disciplina j .

##	#	A	tibble:	8 × 3
##		id	name	size
##	<int>	<chr>	<dbl>	
##	1	1	AGRICULTURE AND FOOD SCIENCE	875440.
##	2	2	ASTRONOMY AND ASTROPHYSICS	381255.
##	3	3	BASIC LIFE SCIENCES	2579591.
##	4	4	BASIC MEDICAL SCIENCES	268387.
##	5	5	BIOLOGICAL SCIENCES	1482123
##	6	6	BIOMEDICAL SCIENCES	2587916.
##	7	7	CHEMISTRY AND CHEMICAL ENGINEERING	3518294.
##	8	8	CIVIL ENGINEERING AND CONSTRUCTION	168983.

Visualizziamo un grafo totalmente connesso, DIRETTO (i pesi non sono simmetrici in entrambe le direzioni, nonostante esista sempre il grafo opposto)



Ho fatto una visualizzazione esteticamente buona e abbastanza interpretabile, mettendo **rossi** solo gli archi con peso nel **4° quartile (Top 25%)**

1. Analisi delle citazioni

Discipline con size maggiore:

Quindi con un maggior numero di articoli scientifici pubblicati

##	#	A	tibble:	5 × 3
##		id	name	size
##	<int>	<chr>	<dbl>	
##	1	9	CLINICAL MEDICINE	6824742.
##	2	25	PHYSICS AND MATERIALS SCIENCE	4889318.
##	3	7	CHEMISTRY AND CHEMICAL ENGINEERING	3518294.
##	4	3	BASIC LIFE SCIENCES	2579591.
##	5	6	BIOMEDICAL SCIENCES	2587916.

Flussi con peso citazione maggiore:

Qual'è la coppia di discipline, tale che ho il flusso maggiore di citazioni tra le 2 discipline (tolte autocitazioni)

##	#	A	tibble:	5 × 3
##		weight	from_name	to_name
##		<dbl>	<chr>	<chr>
##	1	1234379.	BIOMEDICAL SCIENCES	CLINICAL MEDICINE
##	2	1187292.	CLINICAL MEDICINE	BIOMEDICAL SCIENCES
##	3	1886268.	CLINICAL MEDICINE	BASIC LIFE SCIENCES
##	4	1837648.	CHEMISTRY AND CHEMICAL ENGINEERING	PHYSICS AND MATERIALS SCIENCE
##	5	1811528.	PHYSICS AND MATERIALS SCIENCE	CHEMISTRY AND CHEMICAL ENGINEERING

Discipline che si autocitano maggiormente Andiamo a guardare solo i self-loop, quindi osserviamo solo i flussi di citazione che vanno da una disciplina a se stessa

##	1	BASIC LIFE SCIENCES
##	2	CLINICAL MEDICINE
##	3	BIOMEDICAL SCIENCES
##	4	PHYSICS AND MATERIALS SCIENCE
##	5	CHEMISTRY AND CHEMICAL ENGINEERING
##	6	BIOLOGICAL SCIENCES
##	7	ENVIRONMENTAL SCIENCES AND TECHNOLOGY
##	8	ELECTRICAL ENGINEERING AND TELECOMMUNICATION
##	9	EARTH SCIENCES AND TECHNOLOGY
##	10	AGRICULTURE AND FOOD SCIENCE

Discipline che ricevono più citazioni Sommiamo tutti i pesi citazione degli archi entranti per ogni disciplina, e facciamo la classifica delle discipline più citate da altre (tolte le autocitazioni)

##	#	A	tibble:	30 × 2
##		rank	name	
##		<int>	<chr>	
##	1	1	BASIC LIFE SCIENCES	
##	2	2	CLINICAL MEDICINE	
##	3	3	BIOMEDICAL SCIENCES	
##	4	4	PHYSICS AND MATERIALS SCIENCE	
##	5	5	CHEMISTRY AND CHEMICAL ENGINEERING	
##	6	6	BIOLOGICAL SCIENCES	
##	7	7	ENVIRONMENTAL SCIENCES AND TECHNOLOGY	
##	8	8	ELECTRICAL ENGINEERING AND TELECOMMUNICATION	
##	9	9	EARTH SCIENCES AND TECHNOLOGY	
##	10	10	AGRICULTURE AND FOOD SCIENCE	
##	#	i	28	more rows

Discipline che tendono a citare altre discipline Sommiamo tutti i pesi citazione degli archi uscenti per ogni disciplina, e facciamo la classifica delle discipline che più citano altre discipline (tolte le autocitazioni)

##	#	A	tibble:	30 × 2
##		rank	name	
##		<int>	<chr>	
##	1	1	CLINICAL MEDICINE	
##	2	2	BIOMEDICAL SCIENCES	
##	3	3	CHEMISTRY AND CHEMICAL ENGINEERING	
##	4	4	PHYSICS AND MATERIALS SCIENCE	
##	5	5	BASIC LIFE SCIENCES	
##	6	6	BIOLOGICAL SCIENCES	
##	7	7	ENVIRONMENTAL SCIENCES AND TECHNOLOGY	
##	8	8	AGRICULTURE AND FOOD SCIENCE	
##	9	9	ELECTRICAL ENGINEERING AND TELECOMMUNICATION	
##	10	10	HEALTH SCIENCES	
##	#	i	28	more rows

Conclusioni analisi

In conclusione, le discipline dell'area biomedica e delle scienze fisiche emergono come i poli principali del sistema: non solo producono il maggior volume di pubblicazioni, ma risultano anche le più coinvolte negli scambi citazionali, sia come destinatarie che come sorgenti di citazioni. Questo conferma la loro centralità strutturale nella rete scientifica analizzata.

2/3. Normalizzazione dei pesi archi tramite il Peso Atteso

Il flusso atteso dal nodo i al nodo j è definito come:

$$E_{ij} = \frac{out_i \cdot in_j}{n}$$

dove:


- out_i = outflow (somma pesi uscenti) della disciplina i , cioè il numero totale di citazioni emesse da i
- in_j = inflow (somma pesi entranti) della disciplina j , cioè il numero totale di citazioni ricevute da j
- n = flusso totale nella rete (somma di tutti i valori della matrice dei flussi)

Il termine in_j/n rappresenta la probabilità che una citazione vada verso la disciplina j , mentre $out_i \cdot in_j/n$ è quindi il flusso "atteso" da i verso j in un modello puramente casuale basato sui volumi.

##	#	A	tibble:	980 × 5
##		from_name	to_name	weight expected weight_norm
##		<chr>	<chr>	<dbl>
##	1	LANGUAGE AND LINGUISTICS	LANGUAGE	8.8784 223. 362.
##	2	INFORMATION AND COMMUNICATION SCIENCES	INFORM.	7.9464 365. 217.
##	3	POLITICAL SCIENCE AND PUBLIC ADMINISTRAT...	POLITL.	1.7065 1081. 157.
##	4	SOCIAL AND BEHAVIORAL SCIENCES, INTERDISC...	SOCIAL...	7.4464 643. 116.
##	5	CIVIL ENGINEERING AND CONSTRUCTION	CIVIL...	1.2865 1277. 188.
##	6	EDUCATIONAL SCIENCES	EDUCAT.	2.1365 2145. 99.2
##	7	MANAGEMENT AND PLANNING	MANAGE...	1.1565 1168. 98.8
##	#	i	893	more rows

Normalizzazione standard

$$\text{peso normalizzato} = \frac{\text{peso osservato}}{\text{peso atteso}}$$



Anche qui ho messo in rosso solo i gli archi con weights nel 4 quadrante (top 25%).

Gli archi più pesanti **sembrano più equamente distribuiti sui vari nodi**, prima c'erano nodi con totale assenza di "archi pesanti", adesso tutti i nodi li hanno.


Normalizzazione con X-test

$$X_{ij} = \frac{F_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

dove:

- F_{ij} = flusso **osservato** dalla disciplina i alla disciplina j
- E_{ij} = flusso **atteso** dalla disciplina i alla disciplina j , calcolato come

Rete dei flussi normalizzati con X-test (4° quartile evidenziato, grafo diretto)



Molto simile alla normalizzazione precedente

4. Calcola l'entropia quadratica di Rao per ogni nodo

Definizione di entropia quadratica di RAO

L'entropia quadratica di Rao è una **misura di eterogeneità del nodo**. Più un nodo è **diverso** dai nodi del suo vicinato, **più è alta la sua eterogeneità**. Se la relazione è una **relazione di approvazione**, come nel nostro caso : maggiore è il flusso di citazioni, **maggiore è l'approvazione di una disciplina verso un altro**, se una disciplina è approvata da discipline molto diverse tra loro, la disciplina ottiene maggiore **importanza trasversale**. L'entropia quadratica di Rao è definita come:

$$R(p) = \sum_{i,j} p_i \cdot p_j \cdot d_{i,j}$$

dove:

- p_i è la proporzione (probabilità) associata all'elemento i
- $d_{i,j}$ è la dissimilarità, = 1 se $i \neq j$ e = 0 se $i = j$ (cioè non sommiamo il prodotto delle probabilità se il vettore è lo stesso)

Per ogni nodo i , definiamo una distribuzione di probabilità sui suoi vicini:

$$p_{i,j} = \frac{a_{i,j}}{\sum_k a_{i,k}} = \frac{a_{i,j}}{d_i}$$

dove:

- $a_{i,j}$ è il peso dell'arco che va da i a j
- $d_i = \sum_k a_{i,k}$ è il **grado pesato uscente** (out-strength) del nodo i

Da questa definizione segue che:

$$0 \leq p_{i,j} \leq 1 \quad \text{e} \quad \sum_j p_{i,j} = 1$$

quindi

$$p_i = (p_{i,1}, p_{i,2}, \dots, p_{i,n})$$

è una vera e propria distribuzione di probabilità di "outflow" associata al nodo i . p_i = **Quanto è probabile che il nodo i citi un altro nodo j**

Nella formula di RAO: Stiamo quindi sommando tutte le **probabilità combinate** $p_{i,k} \cdot p_{j,k}$, cioè la **probabilità che i citi k e j citi k** => Quindi che i e j citino lo stesso nodo k

Se chiamiamo **distribuzione di probabilità combinata** $p_{i,j}(k)$ = **quanto è probabile che i e j citino lo stesso nodo k**

$$p_{i,j} = (p_{i,1} p_{j,1}, p_{i,2} p_{j,2}, \dots, p_{i,n} p_{j,n})$$

Il prodotto $p_i \cdot p_j$ rappresenta la **somma dei valori della probabilità combinata** $p_{i,j}$. Più le due distribuzioni p_i e p_j assegnano probabilità simili agli stessi nodi k , più questa somma sarà **alta**; al contrario, probabilità molto **diverse** generano prodotti piccoli e la somma complessiva si **riduce**.

Quindi Presi 2 nodi i e j , $p_i \cdot p_j$ è la somma dei valori della distribuzione combinata $p_{i,j}$:

- se la somma è **alta**, i due nodi hanno distribuzioni simili → citano gli altri nodi con probabilità simili → **nodi omogenei** (i e j simili);
- se la somma è **bassa**, le loro probabilità differiscono molto → citano nodi diversi → **nodi eterogenei** (i e j diversi).

In conclusione

Posso calcolare la RAO per ogni nodo i :

$$R(p_i) = \sum_{j=1}^n p_i \cdot p_j \quad \text{dove} \quad p_i p_j = \sum_k p_{i,k} \cdot p_{j,k}$$

I nodi con RAO minore sono **eterogenei/diversi** nella distribuzione delle citazioni verso altre discipline, rispetto agli altri

Calcolo del RAO di ogni nodo

```
library(tidygraph)
library(igraph)

# estraggo la matrice di adiacenza
g_ig <- as_igraph(g)
A <- as.matrix(igraph::get_adjacency(g_ig, attr = "weight"))
n <- nrow(A)

# Distribuzioni p_i - divido per il totale della riga (ogni riga i è la distribuzione p_i)
row_tot <- rowSums(A)
P <- A / row_tot

# similitudine tra distribuzioni: p_i · p_j = sum_k p_i(i,k) · p_j(j,k)
S <- P %*% t(P)

# Rao locale per ogni nodo i = somma su tutti j
rao_local <- rowSums(S)

# Visualizzo quelle più eterogenee
rao_tbl <- tibble(
  id = 1:length(rao_local),
  name = nodes$name,
  rao = rao_local
)

top10_interdisc <- rao_tbl %>%
  arrange(rao) %>%
  slice(1:10)

top10_interdisc
```

```
## # A tibble: 10 × 3
##               id name                rao
##   <int> <chr>                <dbl>
## 1    21 LANGUAGE AND LINGUISTICS      0.876
## 2    19 INFORMATION AND COMMUNICATION SCIENCES 0.986
## 3    26 POLITICAL SCIENCE AND PUBLIC ADMINISTRATION 0.967
## 4     8 CIVIL ENGINEERING AND CONSTRUCTION      0.969
## 5    22 MANAGEMENT AND PLANNING            0.971
## 6    13 EDUCATIONAL SCIENCES              1.00
## 7    38 STATISTICAL SCIENCES              1.01
## 8    17 GENERAL AND INDUSTRIAL ENGINEERING      1.03
## 9    29 SOCIOLOGY AND ANTHROPOLOGY          1.04
## 10     2 ASTRONOMY AND ASTROPHYSICS          1.08
```

Queste sono le **discipline più interdisciplinate**, quindi quelle con una distribuzione delle citazioni verso altri nodi più diversa rispetto al resto del nodi.

Queste sono le **discipline più interdisciplinate**, quindi quelle con una distribuzione delle citazioni verso altri nodi più diversa rispetto al resto dei nodi.

Come visto in precedenza, la maggior parte dei nodi punta verso discipline medico-fisiche, mentre queste più umanistiche punteranno ad altre discipline umanistiche, **diversificandosi dal comportamento comune**