

# ProgettoAttantatiCatanzaro

## Introduzione

L'Università di Barcellona, ha creato una rete con i collegamenti fra gli individui coinvolti negli attentati ai treni pendolari a Madrid 11 marzo 2004. (fonti El Pais e El Mundo, giornali spagnoli)

I nodi sono i possibili attentatori o persone che hanno aiutato nella preparazione del attentato (**individui coinvolti**), il legame può essere di diverso tipo :

- fiducia amicizia
  - legami con Al Qaeda e Osama Bin Laden
  - Co-partecipazione in campi di addestramento/guerre
  - Co-partecipazione in altri attacchi terroristici
- Grafo indiretto**, i legami valgono in entrambe le direzioni

Il peso dell arco corrisponde alla forza del legame da 1 a 4.

```
## # A tibble: 6 × 3
##   id      name
##   <dbl> <chr>
## 1     1 Jamal Zougan
## 2     2 Mohamed Bekkai
## 3     3 Mohamed Chaoui
## 4     4 Vinay Kholy
## 5     5 Suresh Kumar
## 6     6 Mohamed Chesadl
```

---

```
## # A tibble: 6 × 3
##   from   to weight
##   <int> <int> <dbl>
## 1     1     2     1
## 2     2     1     3
## 3     3     1     4
## 4     4     1     5
## 5     5     1     6
## 6     6     1     7
```

---

## Rete persone coinvolte negli attentati



Abdoul Fatah

## Rete persone coinvolte negli attentati



Si notano una serie di nodi più isolati, e un **gruppo centrale molto più unito**

Si intravedono anche che ci sono tra i nodi isolati, gruppi più connessi tra loro rispetto ad altro, dei **possibili cluster**

## 1. similarità tra le coppie di terroristi

**Due nodi sono simili, più condividono gli stessi vicini**, in quanto condividono interessi simili, oppure hanno rapporti con le stesse persone (nostro caso).

Di **similarità locale** (tra 2 nodi) esistono diversi modi (molto simili) per calcolarla, i principali sono :

### Similarità coseno

La similarità coseno tra due nodi  $i$  e  $j$  è definita come:

$$\cos(i,j) = \frac{\mathbf{A}_i \cdot \mathbf{A}_j}{\|\mathbf{A}_i\| \|\mathbf{A}_j\|} = \frac{\sum_k A_{ik} A_{jk}}{\sqrt{\sum_k A_{ik}^2} \sqrt{\sum_k A_{jk}^2}}$$

dove:

- $\mathbf{A}_i$  è la riga  $i$ -esima della matrice di adiacenza  $A$
- $\mathbf{A}_j$  è la riga  $j$ -esima della matrice di adiacenza  $A$
- $\|\mathbf{A}_i\|$  è la norma euclidea del vettore  $\mathbf{A}_i$

Questa formula calcola il **coseno dell'angolo** tra i vettori  $i$  e  $j$ .

Il valore:

- si avvicina a 1 se i due vettori sono quasi identici
- è vicino a 0 se sono indipendenti (ortogonali)
- tende a -1 se puntano in direzioni opposte

Quindi, più i due vettori vanno "nella stessa direzione", più l'angolo tra loro è piccolo, il coseno si avvicina a 1 e i due nodi risultano **molto simili**.

Nel prodotto  $\mathbf{A}_i \cdot \mathbf{A}_j$  otteniamo contributi positivi (+1) quando entrambi i nodi hanno un link verso lo stesso vicino  $k$  (cioè  $A_{ik} = 1$  e  $A_{jk} = 1$ ), **aumentando così la similarità**.

### Similarità di Pearson

La similarità di Pearson tra due nodi  $i$  e  $j$  è definita come:

$$\text{pear}(i,j) = \frac{\text{cov}(\mathbf{A}_i, \mathbf{A}_j)}{\text{SD}(\mathbf{A}_i) \text{SD}(\mathbf{A}_j)} = \frac{\sum_k (A_{ik} - \bar{A}_i)(A_{jk} - \bar{A}_j)}{\sqrt{\sum_k (A_{ik} - \bar{A}_i)^2} \sqrt{\sum_k (A_{jk} - \bar{A}_j)^2}}$$

dove:

- $\text{cov}(\mathbf{A}_i, \mathbf{A}_j)$  è la **covarianza** fra i due vettori
- $\text{SD}(\mathbf{A}_i)$  è la **deviazione standard** di  $\mathbf{A}_i$
- $\bar{A}_i$  è la **media** degli elementi di  $\mathbf{A}_i$

Questa formula è il **coefficiente di correlazione di Pearson**, che misura la **correlazione lineare** tra due vettori: indica quanto le due variabili tendono a crescere o decrescere insieme in modo lineare.

(Nel nostro caso, crescere assieme significa avere un arco 1 nello stesso vicino)

Il valore di  $\text{pear}(i,j)$  varia in  $[-1, 1]$ :

- 1 indica correlazione lineare positiva massima (i due nodi hanno pattern di connessione molto simili)
- 0 indica assenza di correlazione lineare
- 1 indica correlazione lineare negativa massima (quando uno "è connesso", l'altro tende a non esserlo, e viceversa)

## Calcolo la similarità coseno tra tutte le coppie di nodi

```
library(tidyverse)
library(tidygraph)
library(igraph)

# CALCOLO LA MATRICE DI SIMILARITA'

g_ig <- as.igraph(g)

# Calcola la matrice di similarità

cosine_similarity_mat <- function(g, mode = "col") {
  A <- as_adjacency_matrix(g, sparse = FALSE) # matrice di adiacenza piena

  if (mode == "row") {
    A <- t(A)
  }

  euclidean <- function(x) sqrt(drop(x %*% x)) # NORMA EUCLIDEA = somma elementi x^2 del vettore x, e radice quadrata

  d <- apply(A, 2, euclidean) # calcola la norma per ogni vettore colonna colonna, d vettore delle norme
  d[d == 0] <- 1

  D <- diag(1 / d)

  # S = Matrice di similarità Sij, è la similarità coseno sin(i,j) - ovviamente simmetrica
  S <- D %*% t(A) %*% D

  node_names <- V(g)$name
  rownames(S) <- node_names
  colnames(S) <- node_names

  S
}


# S_cos(i,j) = similarità coseno tra il nodo i e il nodo j

S_cos <- cosine_similarity_mat(g_ig, mode = "col")

# VISUALIZZO SOLO I PRIMI 10, TOGLIENDO RIPETIZIONI DEI NODI
# altrimenti i colori si sovrappongono nella visualizzazione

## # A tibble: 10 × 3
##   node_i node_j cosine
##   <chr>   <chr>   <dbl>
## 1 Abddenabi Koujma Anuar Asri Rifaat 1
## 2 Jamal Zougan Mohamed Chaoui 0.929
## 3 Suresh Kumar Vinay Kholy 0.9
## 4 Abu Musad Alsakoui Mohamed Atta 0.9
## 5 Ramzi Binalshibh Shakur 0.9
## 6 Abdeluahid Berrak Otman El Ghaut 0.888
## 7 Hamed Almidan Jamal Almidan 0.869
## 8 Emilio Llano Ivan Granados 0.833
## 9 El Gitanillo Raul Gonzales Perez 0.833
## 10 Aner Aziz Galeb Kalaje 0.825
```

## Coppie di persone coinvolte con maggiore similarità



## 2 Scopri celle terroristiche tramite il clustering e similarità

Il clustering è una tecnica che permette di estrarre sottogruppi di nodi con una forte densità di archi tra loro, **partizionare** nel modo giusto la rete quindi porterebbe ad avere un'elevata **modularità**.

Effettuare una partizione del grafo al **massimo dell'efficienza** è impossibile - **problema NP-Hard**, esistono diversi algoritmi per effettuare il clustering, che sfruttano **euristiche** per avere un buon risultato.

### Applicare il clustering gerarchico per trovare cellule terroristiche

Una di queste tecniche è il clustering gerarchico, che sfrutta una **misura di distanza**.

In generale un qualsiasi valore che indica la vicinanza tra 2 nodi, **minore è la distanza, più vicini sono i nodi**

Noi useremo come base la **similarità coseno**  $\text{sim}(i,j)$ , e la distanza sarà  $d(i,j) = 1 - \text{sim}(i,j)$  (cioè all'avvicinarsi a 1, cioè similarità massima, la distanza si ridurrà verso 0)

L'algoritmo:

- Tutti i nodi inizialmente vengono messi in **cluster singoli**
- A ogni passo: viene calcolata la **similarità tra cluster** tra tutte le coppie di cluster presenti
- I 2 cluster con similarità tra cluster **maggiore** viene unita, e si **ricatcolano** tutte le nuove similarità tra cluster

**Similarità tra cluster** (3 modi di calcolarla):

```
● Single-link

Sim_{CL}(C_1, C_2) = \max_{i \in C_1, j \in C_2} \text{sim}(i, j)

La similarità tra due cluster è determinata dalla coppia più simile.

Equivalente in termini di distanza:

d_{CL}(C_1, C_2) = \min_{i \in C_1, j \in C_2} d(i, j)

cioè la distanza minima, che corrisponde alla massima similarità.

● Complete-link

Sim_{CL}(C_1, C_2) = \min_{i \in C_1, j \in C_2} \text{sim}(i, j)

La similarità tra due cluster è determinata dalla coppia meno simile tra essi.

Equivalente in termini di distanza:

[d_{CL}(C_1, C_2) = \max_{i \in C_1, j \in C_2} d(i, j)]

cioè la distanza massima, che corrisponde alla minima similarità.

● Average-link

Sim_{CL}(C_1, C_2) = \frac{1}{|C_1| |C_2|} \sum_{i \in C_1} \sum_{j \in C_2} \text{sim}(i, j)

La similarità tra due cluster è la media delle similarità tra tutte le coppie di nodi.

Equivalente in termini di distanza:

d_{CL}(C_1, C_2) = 1 - \frac{1}{|C_1| |C_2|} \sum_{i \in C_1} \sum_{j \in C_2} \text{sim}(i, j)

cioè 1 - media delle similarità.
```

```
# Applico il clustering gerarchico

g_ig <- as.igraph(g) # mi servono funzioni di base di igraph, come la matrice di adiacenza
A <- as_adjacency_matrix(g_ig, sparse = FALSE)

#-----

# Calcolo la similarità coseno di ogni coppia di nodi

cosine_similarity_mat <- function(A, mode = c("col", "row")) {
  mode <- match.arg(mode)
  if (mode == "row") A <- t(A)

  euclidean <- function(x) sqrt(sum(x * x)) # NORMA EUCLIDEA = somma elementi x^2 del vettore x, e radice quadrata

  d <- apply(A, 2, euclidean) # calcola la norma per ogni vettore colonna colonna, d vettore delle norme
  d[d == 0] <- 1

  D <- diag(1 / d) # matrice diagonale, ogni elemento è l'inversa della norma 1/||x|| di quella co
lonna

  # S = Matrice di similarità Sij, è la similarità coseno sin(i,j) - ovviamente
simmetrica

  node_names <- V(g_ig)$name
  rownames(S) <- node_names
  colnames(S) <- node_names

  S
}

S_cos <- cosine_similarity_mat(A, mode = "col") # matrice di similarità

#-----

# Nel clustering gerarchico, viene usata una misura di distanza d(i,j) = 1 - cos(i,j)
# costruiamo la matrice delle distanze

d_cos <- as.dist(1 - S_cos)


# CALCOLIAMO IL CLUSTERING GERARCHICO
# in base alle distanze, con il metodo complete-link

hc_cos_complete <- hclust(d_cos, method = "complete")

# Appliciamo alla visualizzazione il cut del dendrogramma quando vengono creati 10 clusters

k_clusters = 10
```

## Cluster attentatori



### Interpretazione dei cluster individuati

Avendo utilizzato la **similarità coseno** come misura di vicinanza tra due nodi, è del tutto normale osservare che alcuni individui non siano direttamente collegati tra loro ma vengano comunque assegnati allo stesso cluster.

Questo accade perché il clustering non raggruppa in base alla distanza fisica nel grafo, ma in base alla **similarità dei loro pattern di connessioni**.

se due soggetti condividono molti vicini in comune, la loro similarità coseno risulta elevata e vengono quindi aggregati nella stessa cellula, anche se non sono reciprocamente collegati.

## Analisi delle cellule terroristiche identificate

Dall'analisi risultano visibili alcune cellule principali:

- Cluster 5**
  - È una delle cellule più evidenti. È composta principalmente da **membri di origine spagnola**, che sembrano fare riferimento a figure chiave di collegamento.
  - In particolare emerge il ruolo di **Semaan Gaby Eid** come vero e proprio **intermediario**, ponte tra i membri spagnoli e il resto della rete.
- Cluster 1 (rosso)**
  - È la cellula più grande e densa, contenente il maggior numero di individui coinvolti.
  - Rappresenta il nucleo centrale della rete, caratterizzato da forte interconnessione interna.

## Gruppi minori e nodi periferici

Si identificano inoltre alcuni cluster più piccoli:

- Cluster 4 e Cluster 8**
  - Appaiono come gruppi secondari, marginali rispetto al nucleo centrale. Sono probabilmente sottogruppi locali o cellule operative minori.
- Cluster 16, 17 e 18**
  - Questi gruppi presentano uno o pochissimi membri e sono caratterizzati da bassa connettività.
  - Si configurano come "lupi solitari", soggetti che hanno poche relazioni dirette ma risultano comunque simili (per pattern di connessioni) a un particolare gruppo.